

Kalman 滤波的数学原理

Eliauk

2026 年 2 月 27 日

目录

1	数学准备	2
1.1	随机微分方程 (SDE)	2
2	基础 Kalman 滤波: 基于最大后验估计	2
2.1	连续时间系统的离散化	2
2.2	基于最大后验的 Kalman 滤波	3
2.3	最大后验估计的概率解释	4
3	误差状态 Kalman 滤波	5
4	迭代的误差状态 Kalman 滤波	8
4.1	与 Gauss-Newton 方法的关系	10
5	不变 Kalman 滤波	10
5.1	对数线性性质	11

1 数学准备

1.1 随机微分方程 (SDE)

2 基础 Kalman 滤波：基于最大后验估计

2.1 连续时间系统的离散化

考虑一个带有加性高斯白噪声的连续时间线性时变系统. 在严密的随机微积分框架下, 我们避免使用不严谨的“连续白噪声”概念, 而是使用多维标准 Brown 运动 (Wiener 过程) W_t 的随机微分方程来描述系统的过程演化:

$$dX_t = A(t)X_t dt + B(t)u(t) dt + G(t) dW_t, \quad (1)$$

其中 $\{X_t\}_{t \geq 0}$ 是 $\mathbb{R}^n$ 中的随机过程, W_t 是多维的一般 Brown 运动, 这意味着 W_t 的各个分量独立, 并且对于任意 $t > s$, 增量 $W_t - W_s$ 服从正态分布 $\mathcal{N}\left(\mathbf{0}, \int_s^t Q_c(\tau) d\tau\right)$, 其中 $Q_c(t)$ 是一个时间相关的正定矩阵, 称为功率谱密度矩阵. 系数矩阵 $A(t) \in \mathbb{R}^{n \times n}$ 是系数矩阵, $u(t) \in \mathbb{R}^p$ 是控制输入, $G(t)$ 是噪声驱动矩阵.

假设我们在离散时间序列 $\{t_k\}_{k \geq 0}$ 上进行采样, 我们需要计算 t_{k-1} 到 t_k 的状态转移关系. 首先, 我们定义状态转移矩阵 $\Phi(t, s)$ 是满足以下矩阵微分方程的矩阵函数:

$$\frac{d}{dt} \Phi(t, s) = A(t) \Phi(t, s), \quad \Phi(s, s) = I.$$

对 $\Phi(t_k, t)X_t$ 应用 Itô 公式, 我们得到

$$d(\Phi(t_k, t)X_t) = -\Phi(t_k, t)A(t)X_t dt + \Phi(t_k, t) dX_t, \quad (2)$$

注意由于 $\Phi(t_k, t)X_t$ 对 X_t 的各项的二阶导数为零, 因此 (2) 式中没有二阶项. 将 dX_t 的表达式 (1) 代入 (2), 我们得到

$$d(\Phi(t_k, t)X_t) = \Phi(t_k, t)B(t)u(t) dt + \Phi(t_k, t)G(t) dW_t.$$

在区间 $[t_{k-1}, t_k]$ 上对上式积分, 我们得到

$$X_{t_k} = \Phi(t_k, t_{k-1})X_{t_{k-1}} + \int_{t_{k-1}}^{t_k} \Phi(t_k, t)B(t)u(t) dt + \int_{t_{k-1}}^{t_k} \Phi(t_k, t)G(t) dW_t.$$

我们记 $x_k = X_{t_k}$, 于是离散化的状态转移方程为

$$x_k = \Phi(t_k, t_{k-1})x_{k-1} + \int_{t_{k-1}}^{t_k} \Phi(t_k, t)B(t)u(t) dt + \int_{t_{k-1}}^{t_k} \Phi(t_k, t)G(t) dW_t. \quad (3)$$

记

$$w_{k-1} = \int_{t_{k-1}}^{t_k} \Phi(t_k, t) \mathbf{G}(t) dW_t,$$

根据 Itô 等距, 离散过程噪声 w_{k-1} 是零均值的 Gauss 随机变量, 其协方差矩阵为

$$\mathbf{Q}_{k-1} = \mathbb{E}[w_{k-1} w_{k-1}^\top] = \int_{t_{k-1}}^{t_k} \Phi(t_k, t) \mathbf{G}(t) \mathbf{Q}_c(t) \mathbf{G}(t)^\top \Phi(t_k, t)^\top dt. \quad (4)$$

于是, 我们得到了离散时间的系统模型为

$$x_k = \mathbf{F}_{k-1} x_{k-1} + \mathbf{B}_{k-1} \mathbf{u}_{k-1} + w_{k-1}, \quad w_{k-1} \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_{k-1}). \quad (5)$$

其中 $\mathbf{F}_{k-1} = \Phi(t_k, t_{k-1})$ 是状态转移矩阵, $\mathbf{B}_{k-1} = \int_{t_{k-1}}^{t_k} \Phi(t_k, t) \mathbf{B}(t) dt$ 是离散化的控制输入矩阵, 这里我们假设 $\mathbf{u}(t)$ 在 $[t_{k-1}, t_k]$ 上是常数 $\mathbf{u}_{k-1}$.

2.2 基于最大后验的 Kalman 滤波

假设我们有离散的观测模型

$$z_k = \mathbf{H}_k x_k + v_k, \quad v_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k), \quad (6)$$

Kalman 滤波的目标是在已知所有历史观测 $z_1, \dots, z_k$ 的条件下, 估计当前状态 x_k 的后验分布 $p(x_k | z_{1:k})$.

首先我们需要计算先验分布 $p(x_k | z_{1:k-1})$, 我们直接计算条件期望 $\hat{x}_{k|k-1} = \mathbb{E}[x_k | z_{1:k-1}]$, 即在给定过去观测的条件下对当前状态的预测. 根据 (5) 式, 我们有

$$\hat{x}_{k|k-1} = \mathbf{F}_{k-1} \hat{x}_{k-1|k-1} + \mathbf{B}_{k-1} \mathbf{u}_{k-1}, \quad (7)$$

于是

$$x_k - \hat{x}_{k|k-1} = \mathbf{F}_{k-1} (x_{k-1} - \hat{x}_{k-1|k-1}) + w_{k-1}.$$

所以 $\hat{x}_{k|k-1}$ 的协方差为

$$\hat{\mathbf{P}}_{k|k-1} = \mathbb{E}[(x_k - \hat{x}_{k|k-1})(x_k - \hat{x}_{k|k-1})^\top] = \mathbf{F}_{k-1} \hat{\mathbf{P}}_{k-1|k-1} \mathbf{F}_{k-1}^\top + \mathbf{Q}_{k-1}. \quad (8)$$

于是先验分布 $p(x_k | z_{1:k-1})$ 是一个均值为 $\hat{x}_{k|k-1}$, 协方差为 $\hat{\mathbf{P}}_{k|k-1}$ 的正态分布.

根据 Bayes 定理, 后验分布 $p(x_k | z_{1:k})$ 与先验分布 $p(x_k | z_{1:k-1})$ 和似然函数 $p(z_k | x_k)$ 成正比:

$$p(x_k | z_{1:k}) \propto p(z_k | x_k) p(x_k | z_{1:k-1}),$$

带入 (6) 式和先验分布的表达式, 我们得到

$$p(x_k | z_{1:k}) \propto \exp\left(-\frac{1}{2}\|z_k - \mathbf{H}_k x_k\|_{\mathbf{R}_k^{-1}}^2\right) \exp\left(-\frac{1}{2}\|x_k - \hat{x}_{k|k-1}\|_{\hat{\mathbf{P}}_{k|k-1}^{-1}}^2\right), \quad (9)$$

其中 $\|x\|_{\mathbf{M}}^2 = x^\top \mathbf{M} x$ 表示 Mahalanobis 距离的平方. 最大后验概率要求我们最大化 (9) 式, 这等价于最小化负对数似然函数 $J(x_k)$:

$$J(x_k) = \frac{1}{2}\|z_k - \mathbf{H}_k x_k\|_{\mathbf{R}_k^{-1}}^2 + \frac{1}{2}\|x_k - \hat{x}_{k|k-1}\|_{\hat{\mathbf{P}}_{k|k-1}^{-1}}^2. \quad (10)$$

这只需要对 $J(x_k)$ 关于 x_k 求导, 我们有

$$\hat{\mathbf{P}}_{k|k-1}^{-1}(x_k - \hat{x}_{k|k-1}) - \mathbf{H}_k^\top \mathbf{R}_k^{-1}(z_k - \mathbf{H}_k x_k) = 0,$$

也即

$$\begin{aligned} (\hat{\mathbf{P}}_{k|k-1}^{-1} + \mathbf{H}_k^\top \mathbf{R}_k^{-1} \mathbf{H}_k) x_k &= \hat{\mathbf{P}}_{k|k-1}^{-1} \hat{x}_{k|k-1} + \mathbf{H}_k^\top \mathbf{R}_k^{-1} z_k \\ &= (\hat{\mathbf{P}}_{k|k-1}^{-1} + \mathbf{H}_k^\top \mathbf{R}_k^{-1} \mathbf{H}_k) \hat{x}_{k|k-1} + \mathbf{H}_k^\top \mathbf{R}_k^{-1} (z_k - \mathbf{H}_k \hat{x}_{k|k-1}), \end{aligned}$$

令 $\hat{\mathbf{P}}_{k|k} = (\hat{\mathbf{P}}_{k|k-1}^{-1} + \mathbf{H}_k^\top \mathbf{R}_k^{-1} \mathbf{H}_k)^{-1}$, 我们得到

$$x_k = \hat{x}_{k|k-1} + \hat{\mathbf{P}}_{k|k} \mathbf{H}_k^\top \mathbf{R}_k^{-1} (z_k - \mathbf{H}_k \hat{x}_{k|k-1}).$$

通常我们记这个最优的 x_k 为 $\hat{x}_{k|k}$, 并且利用 Sherman-Morrison-Woodbury 公式, 我们可以将 $\hat{\mathbf{P}}_{k|k}$ 的表达式化简为

$$\hat{\mathbf{P}}_{k|k} = \hat{\mathbf{P}}_{k|k-1} - \hat{\mathbf{P}}_{k|k-1} \mathbf{H}_k^\top (\mathbf{R}_k + \mathbf{H}_k \hat{\mathbf{P}}_{k|k-1} \mathbf{H}_k^\top)^{-1} \mathbf{H}_k \hat{\mathbf{P}}_{k|k-1},$$

通常我们记 Kalman 增益为

$$\mathbf{K}_k = \hat{\mathbf{P}}_{k|k-1} \mathbf{H}_k^\top (\mathbf{R}_k + \mathbf{H}_k \hat{\mathbf{P}}_{k|k-1} \mathbf{H}_k^\top)^{-1}, \quad (11)$$

于是 Kalman 滤波的更新方程为

$$\begin{aligned} \hat{x}_{k|k} &= \hat{x}_{k|k-1} + \mathbf{K}_k (z_k - \mathbf{H}_k \hat{x}_{k|k-1}), \\ \hat{\mathbf{P}}_{k|k} &= (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \hat{\mathbf{P}}_{k|k-1}. \end{aligned} \quad (12)$$

2.3 最大后验估计的概率解释

在前面的推导中, 我们通过最大化后验概率来得到 Kalman 滤波的更新方程. 我们采取了两个记号 $\hat{x}_{k|k}$ 和 $\hat{\mathbf{P}}_{k|k}$, 自然的, 我们会想知道它们是否真的对应于后验分布 $p(x_k | z_{1:k})$ 的均值和协方差. 答案是肯定的, 我们现在来证明这一点.

回顾后验概率的表达式 (9), 我们可以将其重写为

$$p(x_k|z_{1:k}) = \eta \exp(-J(x_k)),$$

其中 η 是归一化常数. 我们把 $J(x_k)$ 在最优估计 $\hat{x}_{k|k}$ 处进行 Taylor 展开, 由于 $J(x_k)$ 本身是关于 x_k 的二次型, 所以其展开式中最高只有二阶项, 也即

$$J(x_k) = J(\hat{x}_{k|k}) + \nabla J(\hat{x}_{k|k})^\top (x_k - \hat{x}_{k|k}) + \frac{1}{2} (x_k - \hat{x}_{k|k})^\top \nabla^2 J(\hat{x}_{k|k}) (x_k - \hat{x}_{k|k}),$$

由于 $\hat{x}_{k|k}$ 是 $J(x_k)$ 的极值点, 所以 $\nabla J(\hat{x}_{k|k}) = 0$. 计算 Hessian 矩阵, 我们有

$$\nabla^2 J(x_k) = \hat{P}_{k|k-1}^{-1} + H_k^\top R_k^{-1} H_k = \hat{P}_{k|k}^{-1},$$

因此, 有

$$J(x_k) = J(\hat{x}_{k|k}) + \frac{1}{2} (x_k - \hat{x}_{k|k})^\top \hat{P}_{k|k}^{-1} (x_k - \hat{x}_{k|k}),$$

这表明

$$p(x_k|z_{1:k}) = \eta \exp(-J(\hat{x}_{k|k})) \exp\left(-\frac{1}{2} (x_k - \hat{x}_{k|k})^\top \hat{P}_{k|k}^{-1} (x_k - \hat{x}_{k|k})\right),$$

其中 $\eta \exp(-J(\hat{x}_{k|k}))$ 是一个常数, 这就表明 $p(x_k|z_{1:k})$ 是一个均值为 $\hat{x}_{k|k}$, 协方差为 $\hat{P}_{k|k}$ 的正态分布.

这意味着, 对于线性 Gauss 系统, 虽然通过最大后验估计只是寻找了一个使得后验概率最大的点估计, 但是实际上这完全确定了整个后验分布 $p(x_k|z_{1:k})$, 这个视角赋予了最优估计 $\hat{x}_{k|k}$ 和协方差 $\hat{P}_{k|k}$ 更深刻的统计意义, 使得我们不仅知道最优估计的值, 还知道了这个估计的不确定性. 有了这个视角, 也有利于我们在后面通过投影方法来重新推导 Kalman 滤波的更新方程.

3 误差状态 Kalman 滤波

下面考虑 Lie 群 G 中的系统 X_t . 我们可以把 X_t 视为 G 上的一个光滑曲线, 满足 $X_t \in T_{X_t}G$. 我们采取左平凡化 $T_A G = \{d(L_A)_e(X) \mid X \in \mathfrak{g}\}$, 其中 $\mathfrak{g}$ 是 G 的 Lie 代数, L_A 是 G 上的左乘映射, e 是 G 的单位元. 于是, 我们可以将 X_t 的演化描述为一个 Lie 群上的微分方程:

$$\dot{X}_t = d(L_{X_t})_e (f(t, X_t) + G(t, X_t)w_t)^\wedge, \quad (13)$$

其中 $f: \mathbb{R} \times G \rightarrow \mathbb{R}^n$ 是光滑函数, $(\cdot)^\wedge: \mathbb{R}^n \rightarrow \mathfrak{g}$ 是 Lie 代数同构. 这里 w_t 表示一个白噪声. 我们没有直接使用 SDE 的形式来描述系统的演化, 因为 Lie 群上的 SDE 的定义更为复杂, 涉及到

Stratonovich 积分等概念, 我们放在后面再来讨论. 然后我们定义无噪声的状态 $\hat{X}_t$, 其满足常微分方程:

$$\dot{\hat{X}}_t = d(L_{X_t})_e \left(f(t, \hat{X}_t) \right)^\wedge.$$

我们定义误差状态 $\delta x_t \in \mathbb{R}^n$ 为

$$\delta x_t = X_t \boxminus \hat{X}_t = \log \left(\hat{X}_t^{-1} X_t \right)^\vee,$$

或者说其满足右扰动的形式:

$$X_t = \hat{X}_t \boxplus \delta x_t = \hat{X}_t \exp \left((\delta x_t)^\wedge \right).$$

我们把漂移项 $f(t, X_t)$ 在 $\hat{X}_t$ 处进行一阶 Taylor 展开, 记 $f_t(X_t) = f(t, X_t)$, 根据微分的链式法则, 我们有

$$f_t(X_t) = f_t(\hat{X}_t \boxplus \delta x_t) \approx f_t(\hat{X}_t) + d(f_t)_{\hat{X}_t} \circ d(L_{\hat{X}_t})_e \circ d(\exp)_0 \left((\delta x_t)^\wedge \right),$$

由于 $d(\exp)_0$ 是恒等映射, 所以上式可以化简为

$$f_t(X_t) \approx f_t(\hat{X}_t) + d(f_t)_{\hat{X}_t} \circ d(L_{\hat{X}_t})_e \left((\delta x_t)^\wedge \right),$$

记 $J_f = d(f_t)_{\hat{X}_t} \circ d(L_{\hat{X}_t})_e \circ (\cdot)^\wedge$, 上式可以写成

$$f_t(X_t) \approx f_t(\hat{X}_t) + J_f(\delta x_t).$$

类似的, 我们可以将 $G_t(X_t)$ 在 $\hat{X}_t$ 处进行一阶 Taylor 展开, 有

$$G_t(X_t) \approx G_t(\hat{X}_t) + J_G(\delta x_t).$$

令 $\eta_t = \hat{X}_t^{-1} X_t$, 那么

$$\begin{aligned} \dot{\eta}_t &= \frac{d}{dt}(\hat{X}_t^{-1}) X_t + \hat{X}_t^{-1} \dot{X}_t \\ &= - \left(f_t(\hat{X}_t) \right)^\wedge \eta_t + \eta_t \left(f_t(X_t) + G_t(X_t) w_t \right)^\wedge \\ &\approx - \left(f_t(\hat{X}_t) \right)^\wedge \eta_t + \eta_t \left(f_t(\hat{X}_t) + J_f \delta x_t + G_t(\hat{X}_t) w_t \right)^\wedge. \end{aligned} \tag{14}$$

回顾右 Jacobian 矩阵的定义:

$$\exp(-\xi^\wedge) \exp(\xi^\wedge + \delta \xi^\wedge) \approx dL_{\exp(-\xi^\wedge)} \circ d(\exp)_{\xi^\wedge}(\delta \xi^\wedge) = (J_R(\xi) \delta \xi)^\wedge,$$

也即

$$d(\exp)_{\xi^\wedge}(\delta\xi^\wedge) = dL_{\exp(\xi^\wedge)}(J_R(\xi)\delta\xi)^\wedge,$$

由于 $\eta_t = \exp(\delta x_t)^\wedge$, 所以

$$\dot{\eta}_t = dL_{\eta_t}(J_R(\delta x_t)\delta\dot{x}_t)^\wedge,$$

与 (14) 式比较, 我们得到误差状态 δx_t 的微分方程为

$$\delta\dot{x}_t \approx J_R(\delta x_t)^{-1} \left((I - \text{Ad}_{\eta_t^{-1}}^\vee) f_t(\hat{X}_t) + J_f \delta x_t + G_t(\hat{X}_t) w_t \right).$$

注意到

$$I - \text{Ad}_{\eta_t^{-1}}^\vee = I - \exp(-\text{ad}_{\delta x_t}^\vee) \approx \text{ad}_{\delta x_t}^\vee,$$

所以保留一阶项后, 我们有

$$\delta\dot{x}_t \approx (J_f - \text{ad}_{f_t(\hat{X}_t)}^\vee) \delta x_t + G_t(\hat{X}_t) w_t.$$

然后采取前一节的结论即可完成误差状态 Kalman 滤波的推导.

例 3.1 (IMU 系统). 考虑 IMU 系统状态 $(C, v, r, b_g, b_a) \in \text{SO}(3) \times \mathbb{R}^3 \times \mathbb{R}^3 \times \mathbb{R}^3 \times \mathbb{R}^3$. 其状态满足微分方程

$$\begin{aligned} \dot{C} &= C(\omega - b_g + n_g)^\wedge, \\ \dot{v} &= C(a - b_a + n_a) + g, \\ \dot{r} &= v, \\ \dot{b}_g &= n_{bg}, \\ \dot{b}_a &= n_{ba}. \end{aligned}$$

其中 ω 和 a 分别是陀螺仪和加速度计的测量值, n_g 和 n_a 是测量噪声, n_{bg} 和 n_{ba} 是偏置的随机游走噪声. 我们可以将上述系统写成 (13) 的形式, 然后通过误差状态 Kalman 滤波来进行状态估计. 令 $X = (C, v, r, b_g, b_a)$ 表示系统状态, 那么

$$\dot{X} = d(L_X)_e \left(\begin{bmatrix} \omega - b_g \\ C(a - b_a) + g \\ v \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} n_g \\ C n_a \\ 0 \\ n_{bg} \\ n_{ba} \end{bmatrix} \right)^\wedge,$$

其中

$$f_t(X) = \begin{bmatrix} \omega - b_g \\ C(a - b_a) + g \\ v \\ 0 \\ 0 \end{bmatrix},$$

于是

$$\mathbf{J}_f = \begin{bmatrix} 0 & 0 & 0 & -\mathbf{I} & 0 \\ -(\hat{\mathbf{C}}(a - \hat{\mathbf{b}}_a))^\wedge & 0 & 0 & 0 & -\hat{\mathbf{C}} \\ 0 & \mathbf{I} & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}, \quad \text{ad}_{f(\hat{X})}^\vee = \begin{bmatrix} (\omega - \hat{\mathbf{b}}_g)^\wedge & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix},$$

因此误差状态的微分方程为

$$\delta \dot{x} = \begin{bmatrix} -(\omega - \hat{\mathbf{b}}_g)^\wedge & 0 & 0 & -\mathbf{I} & 0 \\ -(\hat{\mathbf{C}}(a - \hat{\mathbf{b}}_a))^\wedge & 0 & 0 & 0 & -\hat{\mathbf{C}} \\ 0 & \mathbf{I} & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \delta x + \begin{bmatrix} \mathbf{I} & 0 & 0 & 0 \\ 0 & \hat{\mathbf{C}} & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & \mathbf{I} & 0 \\ 0 & 0 & 0 & \mathbf{I} \end{bmatrix} \begin{bmatrix} n_g \\ n_a \\ n_{bg} \\ n_{ba} \end{bmatrix}.$$

4 迭代的误差状态 Kalman 滤波

根据 2.2 节的解释, Kalman 滤波是在最小化代价函数 (10) 式. 现在我们考虑 Lie 群上的状态 X_t , 以及非线性的量测方程

$$z_t = h(X_t) + v_k, \quad v_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k).$$

同样用 x_k 来表示 X_{t_k} , 以及考虑误差状态 $\delta x_k = x_k \boxminus \hat{x}_k$. 首先把量测方程线性化, 得到

$$z_k = h(\hat{x}_k \boxplus \delta x_k) + v_k \approx h(\hat{x}_k) + \text{d}h_{\hat{x}_k} \circ \text{d}(L_{\hat{x}_k})_e(\delta x_k)^\wedge + v_k,$$

通常记 $\mathbf{H}_k = \text{d}h_{\hat{x}_k} \circ \text{d}(L_{\hat{x}_k})_e \circ (\cdot)^\wedge$, 那么有线性量测方程

$$z_k \approx h(\hat{x}_k) + \mathbf{H}_k \delta x_k + v_k.$$

迭代 Kalman 滤波考虑的问题是, 如何解决线性化误差较大时 Kalman 滤波性能下降的问题. 迭代 Kalman 滤波的核心思想是, 在每次更新时, 不仅更新状态估计 $\hat{x}_k$, 还要重新线性化量测方程, 并且迭代这个过程, 直到收敛为止.

与 2.2 节的推导一样, 在非线性的量测的时候, 最大后验估计的代价函数为

$$J(x_k) = \frac{1}{2} \|x_k \boxminus \hat{x}_{k|k-1}\|_{\hat{\mathbf{P}}_{k|k-1}^{-1}}^2 + \frac{1}{2} \|z_k - h(x_k)\|_{\mathbf{R}_k^{-1}}^2. \quad (15)$$

这个式子是精确的, 但是由于 $h(x_k)$ 的非线性, 我们无法直接求解这个优化问题. 迭代 Kalman 滤波的做法是, 在每次迭代中, 使用当前的状态估计 $\hat{x}_k^{(i)}$ 来线性化量测方程, 然后求解线性化后的

Kalman 滤波更新方程, 得到新的状态估计 $\hat{x}_k^{(i+1)}$, 然后重复这个过程, 直到 $\hat{x}_k^{(i)}$ 收敛, 最终得到最优估计 $\hat{x}_{k|k}$. 首先, $\hat{x}_k^{(0)} = \hat{x}_{k|k-1}$. 在 $\hat{x}_k^{(i)}$ 处, 有量测

$$z_k \approx h(\hat{x}_k^{(i)}) + \mathbf{H}_k^{(i)} \delta x_k^{(i)} + v_k \quad (16)$$

对于状态, 有 $x_k = \hat{x}_k^{(i)} \boxplus \delta x_k^{(i)}$, 所以

$$x_k \boxminus \hat{x}_{k|k-1} = (\hat{x}_k^{(i)} \boxplus \delta x_k^{(i)}) \boxminus \hat{x}_{k|k-1} \approx \hat{x}_k^{(i)} \boxminus \hat{x}_{k|k-1} + \mathbf{J}^{(i)} \delta x_k^{(i)}. \quad (17)$$

记 $e^{(i)} = \hat{x}_k^{(i)} \boxminus \hat{x}_{k|k-1}$, 由于

$$\begin{aligned} \log(\hat{x}_{k|k-1}^{-1} \hat{x}_k^{(i)} \exp(\delta x_k^{(i)})) &\approx e^{(i)} + d(\log)_{\hat{x}_{k|k-1}^{-1} \hat{x}_k^{(i)}} \circ d\left(L_{\hat{x}_{k|k-1}^{-1} \hat{x}_k^{(i)}}\right)_e (\delta x_k^{(i)})^\wedge \\ &= e^{(i)} + \mathbf{J}_r^{-1}(e^{(i)}) \delta x_k^{(i)}, \end{aligned}$$

所以 (17) 式中的 $\mathbf{J}^{(i)}$ 就是右 Jacobian 矩阵的逆 $\mathbf{J}_r^{-1}(e^{(i)})$.

将 (16) 式和 (17) 式带入 (15) 式, 我们得到迭代 Kalman 滤波的代价函数为

$$J(\delta x_k^{(i)}) \approx \frac{1}{2} \left\| e^{(i)} + \mathbf{J}^{(i)} \delta x_k^{(i)} \right\|_{\hat{\mathbf{P}}_{k|k-1}^{-1}}^2 + \frac{1}{2} \left\| z_k - h(\hat{x}_k^{(i)}) - \mathbf{H}_k^{(i)} \delta x_k^{(i)} \right\|_{\mathbf{R}_k^{-1}}^2. \quad (18)$$

接下来的求解方法和线性的情况完全一致. 令 $\nabla J(\delta x_k^{(i)}) = 0$, 我们得到方程

$$\left(\mathbf{J}^{(i)\top} \hat{\mathbf{P}}_{k|k-1}^{-1} \mathbf{J}^{(i)} + \mathbf{H}_k^{(i)\top} \mathbf{R}_k^{-1} \mathbf{H}_k^{(i)} \right) \delta x_k^{(i)} = \mathbf{H}_k^{(i)\top} \mathbf{R}_k^{-1} (z_k - h(\hat{x}_k^{(i)})) - \mathbf{J}^{(i)\top} \hat{\mathbf{P}}_{k|k-1}^{-1} e^{(i)}. \quad (19)$$

我们一般把左端的矩阵称为信息矩阵或者说 Hessian 矩阵, 记为

$$\mathbf{S}^{(i)} = \mathbf{J}^{(i)\top} \hat{\mathbf{P}}_{k|k-1}^{-1} \mathbf{J}^{(i)} + \mathbf{H}_k^{(i)\top} \mathbf{R}_k^{-1} \mathbf{H}_k^{(i)}, \quad (20)$$

令 Kalman 增益为

$$\mathbf{K}^{(j)} = (\mathbf{S}^{(i)})^{-1} \mathbf{H}_k^{(i)\top} \mathbf{R}_k^{-1}, \quad (21)$$

那么更新量

$$\delta x_k^{(i)} = \mathbf{K}^{(i)} (z_k - h(\hat{x}_k^{(i)})) - (\mathbf{I} - \mathbf{K}^{(i)} \mathbf{H}_k^{(i)}) \mathbf{J}^{(i)-1} e^{(i)}. \quad (22)$$

最后, 当更新量足够小 $\|\delta x_k^{(j)}\| < \epsilon$ 时, 我们认为收敛, 令最优的估计状态为 $\hat{x}_{k|k} = \hat{x}_k^{(j+1)}$. 根据 2.3 节的解释, 此时状态协方差就是 Hessian 矩阵的逆, 即

$$\hat{\mathbf{P}}_{k|k} = \left(\mathbf{J}^{(j)\top} \hat{\mathbf{P}}_{k|k-1}^{-1} \mathbf{J}^{(j)} + \mathbf{H}_k^{(j)\top} \mathbf{R}_k^{-1} \mathbf{H}_k^{(j)} \right)^{-1} = (\mathbf{I} - \mathbf{K}^{(j)} \mathbf{H}_k^{(j)}) \mathbf{J}^{(j)-1} \hat{\mathbf{P}}_{k|k-1} \mathbf{J}^{(j)-\top}. \quad (23)$$

这就完成了迭代的误差状态 Kalman 滤波的推导.

4.1 与 Gauss-Newton 方法的关系

回到 (15) 式, 对协方差矩阵进行 Cholesky 分解 $\hat{P}_{k|k-1}^{-1} = L_P^\top L_P$ 以及 $R_k^{-1} = L_R^\top L_R$, 我们可以将代价函数 $J(x_k)$ 重写为标准的 ℓ_2 -范数形式:

$$J(x_k) = \frac{1}{2} \|L_P(x_k \ominus \hat{x}_{k|k-1})\|^2 + \frac{1}{2} \|L_R(z_k - h(x_k))\|^2.$$

令

$$r(x_k) = \begin{bmatrix} L_P(x_k \ominus \hat{x}_{k|k-1}) \\ L_R(z_k - h(x_k)) \end{bmatrix},$$

那么

$$J(x_k) = \frac{1}{2} \|r(x_k)\|^2,$$

这是一个标准的非线性最小二乘问题. 迭代 Kalman 滤波的更新步骤实际上就是在求解这个非线性最小二乘问题的 Gauss-Newton 迭代步骤. 这是因为, 我们有

$$r(\hat{x}_k^{(i)} \oplus \delta x_k^{(i)}) \approx r(\hat{x}_k^{(i)}) + \begin{bmatrix} L_P J^{(i)} \\ -L_R H_k^{(i)} \end{bmatrix} \delta x_k^{(i)},$$

所以

$$\begin{aligned} J(\delta x_k^{(i)}) &\approx \frac{1}{2} \left\| r(\hat{x}_k^{(i)}) + \begin{bmatrix} L_P J^{(i)} \\ -L_R H_k^{(i)} \end{bmatrix} \delta x_k^{(i)} \right\|^2 \\ &= \frac{1}{2} \left(\left\| r(\hat{x}_k^{(i)}) \right\|^2 + 2r(\hat{x}_k^{(i)})^\top \begin{bmatrix} L_P J^{(i)} \\ -L_R H_k^{(i)} \end{bmatrix} \delta x_k^{(i)} + (\delta x_k^{(i)})^\top S^{(i)} \delta x_k^{(i)} \right), \end{aligned}$$

回顾这里的 $S^{(i)}$ 就是 (20) 式的 Hessian 矩阵. 于是 $\nabla J(\delta x_k^{(i)}) = 0$ 等价于下面的式子:

$$S^{(i)} \delta x_k^{(i)} = - \begin{bmatrix} L_P J^{(i)} \\ -L_R H_k^{(i)} \end{bmatrix}^\top r(\hat{x}_k^{(i)}), \quad (24)$$

这和 (19) 式是完全一致的. 这就表明, 迭代 Kalman 滤波的更新步骤实际上就是在求解非线性最小二乘问题的 Gauss-Newton 迭代步骤.

5 不变 Kalman 滤波

还是考虑 Lie 群上的状态 X_t , 定义右不变的误差

$$\eta_t = \hat{X}_t X_t^{-1} = \exp(\xi_t^\wedge).$$

(也可以定义左不变的误差 $\eta_t = X_t^{-1} \hat{X}_t$, 这里我们以右不变误差为例进行推导.)

假设系统的动力学为

$$\dot{X}_t = f_{u_t}(X_t), \quad (25)$$

其中 u_t 是系统的输入. 不变 Kalman 滤波所需的系统动力学不能是任意的非线性函数, 它必须满足一种被称为**群仿射**的性质.

定义 5.1 (群仿射系统). 若对于 Lie 群 G 中的任意元素 $X_1, X_2 \in G$, 动力学函数 $f_u : G \rightarrow TG$ 满足

$$f_u(X_1 X_2) = d(R_{X_2})_{X_1} f_u(X_1) + d(L_{X_1})_{X_2} f_u(X_2) - d(L_{X_1})_{X_2} d(R_{X_2})_e f_u(e), \quad (26)$$

其中 $e \in G$ 是单位元, 那么我们说这个系统是群仿射的. 当 G 是矩阵 Lie 群时, 可以写为

$$f_u(X_1 X_2) = f_u(X_1) X_2 + X_1 f_u(X_2) - X_1 f_u(e) X_2.$$

计算 η_t 的微分方程, 我们有

$$\begin{aligned} \dot{\eta}_t &= d(R_{X_t^{-1}})_{\hat{X}_t} \dot{\hat{X}}_t + d(L_{\hat{X}_t})_{X_t^{-1}} \frac{d}{dt}(X_t^{-1}) \\ &= d(R_{X_t^{-1}})_{\hat{X}_t} f_{u_t}(\hat{X}_t) - d(L_{\hat{X}_t})_{X_t^{-1}} \circ d(L_{X_t^{-1}})_e \circ d(R_{X_t^{-1}})_{X_t} f_{u_t}(X_t) \\ &= d(R_{X_t^{-1}})_{\hat{X}_t} f_{u_t}(\hat{X}_t) - d(L_{\eta_t})_e \circ d(R_{X_t^{-1}})_{X_t} f_{u_t}(X_t). \end{aligned} \quad (27)$$

由于 $\hat{X}_t = \eta_t X_t$, 再根据群仿射的性质, 我们有

$$f_{u_t}(\hat{X}_t) = d(R_{X_t})_{\eta_t} f_{u_t}(\eta_t) + d(L_{\eta_t})_{X_t} f_{u_t}(X_t) - d(L_{\eta_t})_{X_t} d(R_{X_t})_e f_{u_t}(e),$$

代入 (27) 式, 我们得到不变误差的微分方程:

$$\dot{\eta}_t = f_{u_t}(\eta_t) - d(L_{\eta_t})_e f(e).$$

令 $g_u(\eta) = f_u(\eta) - d(L_\eta)_e f(e)$, 于是误差的微分方程为

$$\dot{\eta}_t = g_{u_t}(\eta_t). \quad (28)$$

这表明误差 η_t 和当前的状态 $\hat{X}_t$ 无关, 这就是不变 Kalman 滤波的核心思想. 由于误差的演化与当前状态无关, 我们可以直接对误差进行 Kalman 滤波, 而不需要考虑当前状态的影响.

5.1 对数线性性质

按照通常的方式推导线性化的微分方程, 设 $\eta_t = \exp(\xi_t^\wedge)$, 那么 $\dot{\eta}_t = d(L_{\eta_t})_e (\mathbf{J}_R(\xi_t) \dot{\xi}_t)^\wedge$, 所以 ξ_t 应该满足严格的微分方程

$$\dot{\xi}_t = \mathbf{J}_R(\xi_t)^{-1} \left(d(L_{\eta_t^{-1}})_{\eta_t} \circ g_{u_t}(\exp(\xi_t)^\wedge) \right)^\vee. \quad (29)$$

只考虑一阶项, 那么 $d(L_{\eta_t^{-1}})_{\eta_t}$ 近似为恒等映射, 并且设矩阵 $A_{u_t} = d(g_{u_t})_e$, 我们有

$$g_{u_t}(\exp(\xi_t)^\wedge) \approx g_{u_t}(e) + d(g_{u_t})_e \circ d(\exp)_0(\xi_t^\wedge) = d(g_{u_t})_e(\xi_t^\wedge) = (A_{u_t}\xi_t)^\wedge,$$

于是 (29) 式变为

$$\dot{\xi}_t \approx A_{u_t} \xi_t \tag{30}$$