

强化学习的数学原理

Eliauk

2026 年 6 月 15 日

目录

1 Markov 决策过程	1
1.1 带折扣的 Markov 决策过程	1
1.1.1 目标、策略和价值	2
1.1.2 稳定策略的 Bellman 一致性方程	3
1.1.3 Bellman 最优性方程	5

1 Markov 决策过程

1.1 带折扣的 Markov 决策过程

在强化学习中, agent 与环境的交互被建模为一个带折扣的 Markov 决策过程 (Markov Decision Process, MDP):

$$M = (S, \mathcal{A}, P, r, \gamma, \mu).$$

其中各项的定义如下:

- 状态空间 S , 可能有限或者无限. 一般来说, 要求 S 是一个可测空间, 配备一个 σ -代数 $\mathcal{S}$. 为了数学上的便利, 我们要求 S 是有限或者可数无限的.
- 动作空间 $\mathcal{A}$, 同样可能有限或者无限. 一般来说, 要求 $\mathcal{A}$ 是一个可测空间, 配备一个 σ -代数 $\mathcal{A}$. 为了数学上的便利, 我们要求 $\mathcal{A}$ 是有限的.
- 转移函数 $P : (S \times \mathcal{A}) \times \mathcal{S} \rightarrow [0, 1]$, 满足: 对于任意 $(s, a) \in S \times \mathcal{A}$, $P(\cdot | s, a)$ 是 S 上的一个概率测度. 我们也记 $P_{s,a} := P(\cdot | s, a)$.

- 奖励函数 $r : \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$, 表示在状态 s 下执行动作 a 所获得的即时奖励. r 视为 $\mathcal{S} \times \mathcal{A}$ 上的一个随机变量, 且要求 r 是有界的.
- 折扣因子 $\gamma \in [0, 1)$, 定义了问题的有效视野.
- 初值分布 μ , 是 $\mathcal{S}$ 上的一个概率测度, 表示系统的初始状态分布. 在许多情况下, 我们假设初值状态是固定的 s_0 , 即 $\mu = \delta_{s_0}$.

1.1.1 目标、策略和价值

策略 给定 MDP $M = (\mathcal{S}, \mathcal{A}, P, r, \gamma, \mu)$, agent 遵从下面的原则和环境进行交互: agent 从某个状态 $s_0 \sim \mu$ 开始; 在每个时间 $t = 0, 1, 2, \dots$ 处, agent 首先观测当前状态 s_t , 然后选择一个动作 $a_t \in \mathcal{A}$, 获得一个即时奖励 $r_t = r(s_t, a_t)$, 最后再观测下一个状态 $s_{t+1} \sim P(\cdot | s_t, a_t)$.

在一个决策时间 t 时, 约定历史信息为截至 t 的可观测的状态和动作的序列, 即

$$\tau_t := (s_0, a_0, s_1, a_1, \dots, s_{t-1}, a_{t-1}, s_t).$$

注意到 τ_t 中不包含 a_t , 因为 a_t 是在历史信息 τ_t 的基础上选择的.

在最一般的情况下, 一个策略指的是 agent 自适应地根据历史信息来选择动作的规则. 准确地说, 一个策略是一个映射 $\pi : \mathcal{H} \times \mathcal{A} \rightarrow [0, 1]$, 其中 $\mathcal{H}$ 包含所有有限长的历史信息. 在时间 t 处, 动作采样于 $a_t \sim \pi(\cdot | \tau_t)$.

一个稳定策略 π 是一个映射 $\pi : \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$, 满足: 对于任意 $s \in \mathcal{S}$, $\pi(\cdot | s)$ 是 $\mathcal{A}$ 上的一个概率测度. 也即, agent 选取的动作采样于 $a_t \sim \pi(\cdot | s_t)$, 只依赖于当前状态 s_t . 一个确定性的稳定策略指的是映射 $\pi : \mathcal{S} \rightarrow \mathcal{A}$, 满足 $\pi(s) \in \mathcal{A}$, 即在状态 s 下总是选择动作 $\pi(s)$.

价值 我们现在定义一般策略的价值. 对于一个策略 π 和初始状态 $S_0 = s$, 我们定义价值函数 $V_M^\pi : \mathcal{S} \rightarrow \mathbb{R}$ 为

$$V_M^\pi(s) = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r(S_t, A_t) \mid S_0 = s \right].$$

这里的期望相对于轨迹的随机性 (依赖于状态转移和策略 π). 因为 $r(s, a) \in [0, 1]$, 所以 $0 < V_M^\pi(s) \leq \sum_{t=0}^{\infty} \gamma^t = \frac{1}{1-\gamma}$.

类似地, 定义动作价值函数 $Q_M^\pi : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 为

$$Q_M^\pi(s, a) = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r(S_t, A_t) \mid S_0 = s, A_0 = a \right].$$

显然 $Q_M^\pi(s, a)$ 也有上界 $\frac{1}{1-\gamma}$.

目标 给定状态 s , agent 的目标是寻找策略 π 使得最大化价值:

$$\sup_{\pi} V_M^{\pi}(s), \quad (1)$$

其中上确界针对所有可能的 (非稳定的或者随机的) 策略. 我们将看到, 存在一个稳定的确定性策略对于所有初始状态 s 都是最优的.

为了简化记号, 我们有时候会省略 MDP 的下标 M , 直接写成 V^{π} 和 Q^{π} .

例 1.1 (导航). 导航也许是最简单的强化学习的例子. 状态是 agent 的当前位置. 动作为东南西北四个移动方向. 此时状态转移函数是确定性的. agent 有一个目标状态 g , 当 agent 到达目标状态 g 时获得奖励 1, 其他时候奖励为 0. 因为 $\gamma < 1$, 所以存在一个激励使得 agent 尽快地到达目标状态 g . 因此, 最优的行为是找到从起点到目标状态 g 的最短路径. 如果策略在 d 步到达目标并且保持在目标状态, 那么价值函数的值为 γ^d .

例 1.2 (策略游戏). 这是一类很受欢迎的应用场景, 强化学习已经在围棋、国际象棋以及各种形式的扑克中达到了人类水平的表现. 通常, 状态是当前的游戏局面, 动作是合法的走法, 而奖励则是最终的胜负结果 (或者是更详细的得分). 从技术上讲, 这些属于多 agent 环境, 但许多成功的方法使用的技术并不会显式地对多个 agent 建模.

1.1.2 稳定策略的 Bellman 一致性方程

稳定策略满足下面的一致性条件:

引理 1.3. 假设 π 是稳定策略, 那么 V^{π} 和 Q^{π} 满足下面的 Bellman 一致性方程: 对于任意 $s \in \mathcal{S}$ 和 $a \in \mathcal{A}$, 有

$$\begin{aligned} V^{\pi}(s) &= \mathbb{E}_{a \sim \pi(\cdot|s)}[Q^{\pi}(s, a)], \\ Q^{\pi}(s, a) &= r(s, a) + \gamma \mathbb{E}_{s' \sim P(\cdot|s, a)}[V^{\pi}(s')]. \end{aligned}$$

特别地, 如果 π 是确定性的, 那么 $V^{\pi}(s) = Q^{\pi}(s, \pi(s))$.

Proof. 直接利用条件期望的塔式法则, 我们有

$$\mathbb{E} \left[\mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r(S_t, A_t) \mid S_0, A_0 \right] \mid S_0 \right] = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r(S_t, A_t) \mid S_0 \right],$$

右端是 V^π , 左端是 $\mathbb{E}_{a \sim \pi(\cdot|S_0)}[Q^\pi(S_0, a)]$. 对于第二点, 有

$$\begin{aligned} Q^\pi &= \mathbb{E} \left[r(S_0, A_0) + \sum_{t=1}^{\infty} \gamma^t r(S_t, A_t) \mid S_0, A_0 \right] \\ &= r(S_0, A_0) + \gamma \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r(S_{t+1}, A_{t+1}) \mid S_0, A_0 \right] \\ &= r(S_0, A_0) + \gamma \mathbb{E} \left[\mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r(S_{t+1}, A_{t+1}) \mid S_1 \right] \mid S_0, A_0 \right] \\ &= r(S_0, A_0) + \gamma \mathbb{E}_{s' \sim P(\cdot|S_0, A_0)}[V^\pi(s')]. \end{aligned} \quad \square$$

换一个视角, 把 V^π 视为长度 $|S|$ 的向量, Q^π 视为长度 $|S| \cdot |A|$ 的向量. 记符号 P 为转移函数 P 的矩阵表示, 即一个 $|S| \cdot |A|$ 行 $|S|$ 列的矩阵, 满足 $P_{(s,a),s'} = P(s'|s, a)$. 同时记 P^π 是稳定策略 π 诱导的状态-动作对的转移矩阵:

$$P_{(s,a),(s',a')}^\pi = P(s'|s, a)\pi(a'|s').$$

特别的, 对于确定性策略, 有

$$P_{(s,a),(s',a')}^\pi = \begin{cases} P(s'|s, a) & \text{if } a' = \pi(s'), \\ 0 & \text{otherwise.} \end{cases}$$

在这个记号下, 可以直接验证得到:

$$Q^\pi = r + \gamma P V^\pi = r + \gamma P^\pi Q^\pi.$$

推论 1.4. 假设 π 是稳定策略, 那么

$$Q^\pi = (I - \gamma P^\pi)^{-1} r, \quad (2)$$

其中 I 是 $|S| \cdot |A|$ 维的单位矩阵.

Proof. 只需要说明 $I - \gamma P^\pi$ 是可逆的. 注意到对于任意非零的向量 $x \in \mathbb{R}^{|S||A|}$, 有

$$\|(I - \gamma P^\pi)x\|_\infty \geq \|x\|_\infty - \gamma \|P^\pi x\|_\infty \geq \|x\|_\infty - \gamma \|x\|_\infty = (1 - \gamma)\|x\|_\infty > 0.$$

其中第一步利用了三角不等式, 第二步利用了 P^π 是一个转移矩阵, 所以 $\|P^\pi x\|_\infty \leq \|x\|_\infty$. $\square$

1.1.3 Bellman 最优性方程

带折扣的 MDP 的一个非常重要和方便的性质是, 存在一个稳定和确定性的策略使得对于所有的 $s \in \mathcal{S}$ 都能最大化 $V^\pi(s)$.

定理 1.5. 令 Π 是所有策略 (可能是非稳定的或者随机的) 的集合. 定义

$$V^*(s) = \sup_{\pi \in \Pi} V^\pi(s), \quad Q^*(s, a) = \sup_{\pi \in \Pi} Q^\pi(s, a).$$

那么存在一个稳定的确定性策略 π , 使得对于所有 $s \in \mathcal{S}$ 和 $a \in \mathcal{A}$, 满足

$$V^\pi(s) = V^*(s), \quad Q^\pi(s, a) = Q^*(s, a).$$

我们把这样的策略称为最优策略.

Proof. 我们首先证明: 在考虑一步历史 $(S_0, A_0, S_1) = (s, a, s')$ 的条件下, 最大的未来折扣回报不依赖于 (s, a) 的值. 准确地说, 我们证明下面的式子:

$$\sup_{\pi \in \Pi} \mathbb{E} \left[\sum_{t=1}^{\infty} \gamma^t r(S_t, A_t) \mid S_0 = s, A_0 = a, S_1 = s' \right] = \gamma V^*(s'). \quad (3)$$

固定任意策略 π . 定义一个“偏移”策略 $\pi_{(s,a)}$ 如下: 对于 $t \geq 0$ 和历史 $(s_0, a_0, \dots, s_t)$, 有

$$\begin{aligned} \pi_{(s,a)}(A_t = b \mid S_0 = s_0, A_0 = a_0, \dots, S_t = s_t) \\ = \pi(A_{t+1} = b \mid S_0 = s, A_0 = a, S_1 = s_0, A_1 = a_0, \dots, S_{t+1} = s_t). \end{aligned}$$

那么在已知 $(S_0, A_0, S_1) = (s, a, s')$ 的条件下策略 π 的表现, 与已知 $S_0 = s'$ 的条件下策略 $\pi_{(s,a)}$ 的表现完全一样. 也就是说, 有

$$\mathbb{E}^\pi \left[\sum_{t=1}^{\infty} \gamma^t r(S_t, A_t) \mid (S_0, A_0, S_1) = (s, a, s') \right] = \gamma \mathbb{E}^{\pi_{(s,a)}} \left[\sum_{t=0}^{\infty} \gamma^t r(S_t, A_t) \mid S_0 = s' \right] = \gamma V^{\pi_{(s,a)}}(s').$$

此外, 对于每个 (s, a) , 集合 $\{\pi_{(s,a)} : \pi \in \Pi\}$ 与 Π 是相同的. 因此, 有

$$\sup_{\pi \in \Pi} \mathbb{E}^\pi \left[\sum_{t=1}^{\infty} \gamma^t r(S_t, A_t) \mid (S_0, A_0, S_1) = (s, a, s') \right] = \gamma \sup_{\pi \in \Pi} V^{\pi_{(s,a)}}(s') = \gamma V^*(s').$$

这就证明了 (3) 式.

□