

强化学习的数学原理

Eliauk

2026 年 5 月 17 日

目录

1 系统动力学的公理化构造	1
2 无穷维轨迹空间与目标泛函	2
3 策略梯度	3

1 系统动力学的公理化构造

本节我们构建强化学习的系统框架，即马尔可夫决策过程 (Markov Decision Process, MDP)。我们将从最基本的概念出发，逐步建立起 MDP 的数学定义。

MDP 指的是一个六元组 $(S, A, \mathcal{P}, r, \rho_0, \gamma)$ ，其中：

- (1) **状态空间**. 系统所有可能的状态的集合，记为 S 。默认是一个可测空间，配备一个 σ -代数 $\mathcal{S}$ 。
- (2) **动作空间**. 系统所有可能的动作的集合，记为 A 。同样是一个可测空间，配备一个 σ -代数 $\mathcal{A}$ 。为了描述系统的交互，还会考虑乘积空间 $S \times A$ ，配备 σ -代数 $\mathcal{S} \otimes \mathcal{A}$ 。
- (3) **状态转移核**. 状态转移核 $\mathcal{P}$ 指的是一个从 $S \times A$ 到 $\mathcal{S}$ 的转移概率，也即映射

$$\mathcal{P} : (S \times A) \times \mathcal{S} \rightarrow [0, 1],$$

满足：对于任意 $(s, a) \in S \times A$ ， $\mathcal{P}(s, a, \cdot)$ 是 $\mathcal{S}$ 上的一个概率测度；对于任意 $E \in \mathcal{S}$ ， $\mathcal{P}(\cdot, \cdot, E)$ 是 $S \times A$ 上的一个可测函数。通常，我们记 $\mathcal{P}(E|s, a) := \mathcal{P}(s, a, E)$ ，表示在状态 s 下执行动作 a 后状态集 E 出现的概率。

- (4) **奖励函数**. 奖励函数 r 是 $S \times A$ 上的有界实值随机变量。

(5) **初始状态分布**. ρ_0 是 S 上的一个概率测度, 表示系统的初始状态分布.

(6) **折扣因子**. $\gamma \in [0, 1)$ 是一个实数, 表示未来奖励的折扣率.

在此基础上, 我们需要优化的目标是一个策略 π_θ , 它是从 S 到 A 的转移概率, 所以满足: 对于任意 $s \in S$, $\pi_\theta(s, \cdot)$ 是 A 上的一个概率测度; 对于任意 $E \in \mathcal{A}$, $\pi_\theta(\cdot, E)$ 是 S 上的一个可测函数. 同样记 $\pi_\theta(E|s) := \pi_\theta(s, E)$, 表示在状态 s 下选择动作集 E 的概率. θ 表示策略的参数.

2 无穷维轨迹空间与目标泛函

在强化学习中, 系统的完整状态是一条无限长的序列, 我们需要构造一个容纳所有可能轨迹的空间.

对于每个时刻 $t \in \mathbb{N}$, 系统的状态是一个二元组 $(s_t, a_t) \in S \times A$, 表示在时刻 t 的状态和动作. 因此, 系统的完整状态可以表示为一个无限长的序列 $\tau = ((s_0, a_0), (s_1, a_1), \dots)$, 其中每个 $(s_t, a_t) \in S \times A$. 因此我们的状态空间应该是

$$\Omega = (S \times A)^{\mathbb{N}} = \prod_{t=0}^{\infty} S \times A,$$

其配备自然的 σ -代数 $\mathcal{F}$, 由所有有限维的柱集生成.

接下来我们要给 $(\Omega, \mathcal{F})$ 赋予一个概率测度 $\mathbb{P}_\theta$. 现在我们拥有的是:

- 初始概率测度 $\rho_0(ds_0)$.
- 策略核 $\pi_\theta(da_t|s_t)$, 即给定状态输出动作的概率测度.
- 系统转移核 $\mathcal{P}(ds_{t+1}|s_t, a_t)$, 即给定当前时刻状态和动作输出下一个时刻状态的概率测度.

我们定义一个从 $S \times A$ 到 $S \times A$ 的联合转移核

$$K_\theta(ds_{t+1}, da_{t+1}|s_t, a_t) := \mathcal{P}(ds_{t+1}|s_t, a_t)\pi_\theta(da_{t+1}|s_{t+1}).$$

换句话说, 给定 s_t, a_t , $K_\theta(\cdot|s_t, a_t)$ 是积测度 $\mathcal{P}(\cdot|s_t, a_t) \otimes \pi_\theta(\cdot|s_{t+1})$, 根据 Ionescu-Tulcea 定理, 空间 $(\Omega, \mathcal{F})$ 上存在唯一的概率测度 $\mathbb{P}_\theta$, 使得对于任意时间 $T \in \mathbb{N}$ 和可测集 $B_0, B_1, \dots, B_T \in \mathcal{S}$ 以及 $C_0, C_1, \dots, C_T \in \mathcal{A}$, 满足

$$\begin{aligned} & \mathbb{P}_\theta((B_0 \times C_0) \times (B_1 \times C_1) \times \dots \times (B_T \times C_T) \times (S \times A)^{\mathbb{N}}) \\ &= \int_{B_0} \rho_0(ds_0) \int_{C_0} \pi_\theta(da_0|s_0) \int_{B_1 \times C_1} K_\theta(ds_1, da_1|s_0, a_0) \dots \int_{B_T \times C_T} K_\theta(ds_T, da_T|s_{T-1}, a_{T-1}) \\ &= \int_{B_0 \times C_0} \int_{B_1 \times C_1} \dots \int_{B_T \times C_T} \rho_0(ds_0) \pi_\theta(da_0|s_0) \prod_{t=0}^{T-1} K_\theta(ds_{t+1}, da_{t+1}|s_t, a_t) \end{aligned}$$

这也表明 $\mathbb{P}_\theta$ 有概率密度函数

$$p_\theta(\tau) = \prod_{t=-1}^{\infty} K_\theta(s_{t+1}, a_{t+1} | s_t, a_t). \quad (1)$$

这里为了方便, 记 $K_\theta(ds_0, da_0 | s_{-1}, a_{-1}) = \rho_0(ds_0)\pi_\theta(da_0 | s_0)$.

有了概率空间 $(\Omega, \mathcal{F}, \mathbb{P}_\theta)$, 我们就可以定义强化学习的目标函数了. 定义投影函数 $X_t : \Omega \rightarrow S \times A$ 为 $X_t(\tau) = (s_t, a_t)$, 其中 $\tau = ((s_0, a_0), (s_1, a_1), \dots) \in \Omega$. 我们定义单步奖励是复合函数 $r_t = r \circ X_t : \Omega \rightarrow \mathbb{R}$, 即

$$r_t(\tau) = r(s_t, a_t).$$

r_t 是 Ω 上的有界实值随机变量. 通过折扣因子 γ , 我们定义整条轨迹的累计奖励为无穷级数

$$R(\tau) = \sum_{t=0}^{\infty} \gamma^t r_t(\tau). \quad (2)$$

由于 r_t 的有界性, $R(\tau)$ 是绝对收敛的, 并且关于 τ 是一致收敛的, 所以 R 也是 Ω 上的一个有界实值随机变量. 也就是说, $R(\tau) \in L^1(\Omega, \mathcal{F}, \mathbb{P}_\theta)$. 最后, 强化学习的目标泛函 $J : \Theta \rightarrow \mathbb{R}$ 定义为随机变量 R 的期望值, 即

$$J(\theta) = \mathbb{E}[R] = \int_{\Omega} R(\tau) \mathbb{P}_\theta(d\tau). \quad (3)$$

可以看到, 强化学习的奖励并不依赖于参数 θ . 参数 θ 唯一控制的变量是概率测度 $\mathbb{P}_\theta$. 因此强化学习优化的本质是在参数空间 Θ 上不断改变测度 $\mathbb{P}_\theta$, 把更多的“概率质量”集中到 R 较大的轨迹集合上.

3 策略梯度

为了书写方便, 我们先对机器学习文献中常见的期望写法进行一些符号上的说明. 对于随机变量 $f : \Omega \rightarrow \mathbb{R}$, 记号 $\mathbb{E}_{x \sim \mathbb{P}}[f(x)]$ 表示 f 关于测度 $\mathbb{P}$ 的期望值, 即

$$\mathbb{E}_{x \sim \mathbb{P}}[f(x)] = \int_{\Omega} f(x) \mathbb{P}(dx).$$

有时候也简写成 $\mathbb{E}_x[f(x)]$. 对于带有转移核的情况, 设两个可测空间 $(E, \mathcal{E})$ 和 $(F, \mathcal{F})$, 以及一个从 E 到 F 的转移核 $K : E \times \mathcal{F} \rightarrow [0, 1]$, $\mathbb{P}$ 是 E 上的概率测度, f 是 $E \times F$ 上的随机变量, 那么记号 $\mathbb{E}_{x \sim \mathbb{P}, y \sim K(\cdot | x)}[f(x, y)]$ 表示

$$\mathbb{E}_{x \sim \mathbb{P}, y \sim K(\cdot | x)}[f(x, y)] = \int_E \int_F f(x, y) K(dy | x) \mathbb{P}(dx).$$

有时候也简写成 $\mathbb{E}_{x \sim \mathbb{P}, y \sim K}[f(x, y)]$ 或者 $\mathbb{E}_{x, y}[f(x, y)]$.

回顾 (3) 式, 结合累计奖励 (2) 和概率密度 (1), 我们可以把目标函数 $J(\theta)$ 展开成如下形式:

$$J(\theta) = \int_{\Omega} \left(\sum_{k=0}^{\infty} \gamma^k r(s_k, a_k) \right) p_{\theta}(\tau) d\tau,$$

对 θ 求梯度, 交换积分和梯度算子, 利用恒等变形 $\nabla_{\theta} p_{\theta}(\tau) = p_{\theta}(\tau) \nabla_{\theta} \log p_{\theta}(\tau)$, 我们得到

$$\nabla_{\theta} J(\theta) = \int_{\Omega} \left(\sum_{k=0}^{\infty} \gamma^k r(s_k, a_k) \right) p_{\theta}(\tau) \nabla_{\theta} \log p_{\theta}(\tau) d\tau = \mathbb{E}_{\tau \sim \mathbb{P}_{\theta}} \left[\nabla_{\theta} \log p_{\theta}(\tau) \sum_{k=0}^{\infty} \gamma^k r(s_k, a_k) \right].$$

再回顾概率密度 (1), 表达式中只有 $\pi_{\theta}(a_t | s_t)$ 依赖于 θ , 所以

$$\nabla_{\theta} \log p_{\theta}(\tau) = \sum_{t=0}^{\infty} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t),$$

代入到上式中, 我们就得到了强化学习的**原始策略梯度表达式**:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \mathbb{P}_{\theta}} \left[\sum_{t=0}^{\infty} \sum_{k=0}^{\infty} \gamma^k r(s_k, a_k) \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right]. \quad (4)$$

原始策略梯度的表达式极难处理, 包含了二重无穷级数, 我们需要利用时间上的因果性来进行一些简化.

记 $S_k : \Omega \rightarrow S$ 和 $A_k : \Omega \rightarrow A$ 分别为时刻 k 的状态和动作的投影函数, 即 $S_k(\tau) = s_k$ 和 $A_k(\tau) = a_k$. 对于每个时刻 t , 我们考虑历史轨迹生成子 σ -代数 $\mathcal{H}_t$:

$$\mathcal{H}_t = \sigma(S_0, A_0, S_1, A_1, \dots, S_{t-1}, A_{t-1}, S_t).$$

利用条件期望的塔式法则, 我们有

$$\mathbb{E}_{\tau} \left[\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \sum_{k=0}^{t-1} \gamma^k r_k \right] = \mathbb{E} \left[\mathbb{E} \left[\nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \sum_{k=0}^{t-1} \gamma^k r_k \middle| \mathcal{H}_t \right] \right],$$

内层期望中, $\sum_{k=0}^{t-1} \gamma^k r_k$ 是 $\mathcal{H}_t$ -可测的, 根据条件期望的性质, 我们可以把它往外提一层, 得到

$$\mathbb{E} \left[\nabla_{\theta} \log \pi_{\theta}(A_t | S_t) \sum_{k=0}^{t-1} \gamma^k r_k \middle| \mathcal{H}_t \right] = \left(\sum_{k=0}^{t-1} \gamma^k r_k \right) \mathbb{E} [\nabla_{\theta} \log \pi_{\theta}(A_t | S_t) | \mathcal{H}_t].$$

其中 $\pi_\theta(A_t|S_t)$ 只有 A_t 是未知信息, 所以有

$$\begin{aligned}\mathbb{E}[\nabla_\theta \log \pi_\theta(A_t|S_t)|\mathcal{H}_t] &= \mathbb{E}[\nabla_\theta \log \pi_\theta(A_t|S_t)|S_t] = \int_A \nabla_\theta \log \pi_\theta(a_t|S_t) \pi_\theta(da_t|S_t) \\ &= \int_A \frac{\nabla_\theta \pi_\theta(a_t|S_t)}{\pi_\theta(a_t|S_t)} \pi_\theta(a_t|S_t) da_t = \int_A \nabla_\theta \pi_\theta(a_t|S_t) da_t \\ &= \nabla_\theta \int_A \pi_\theta(a_t|S_t) da_t = \nabla_\theta 1 = 0.\end{aligned}\tag{5}$$

于是我们有

$$\mathbb{E}_\tau \left[\nabla_\theta \log \pi_\theta(a_t|s_t) \sum_{k=0}^{t-1} \gamma^k r_k \right] = 0.$$

所以 (4) 中关于 k 的求和可以截断到 t , 即

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \mathbb{P}_\theta} \left[\sum_{t=0}^{\infty} \sum_{k=t}^{\infty} \gamma^k r(s_k, a_k) \nabla_\theta \log \pi_\theta(a_t|s_t) \right]. \tag{6}$$

把 t 的求和与期望交换并提取因子 γ^t , 得到

$$\nabla_\theta J(\theta) = \sum_{t=0}^{\infty} \gamma^t \mathbb{E}_{\tau \sim \mathbb{P}_\theta} \left[\nabla_\theta \log \pi_\theta(a_t|s_t) \sum_{k=t}^{\infty} \gamma^{k-t} r(s_k, a_k) \right].$$

继续利用条件期望的塔式法则, 我们有

$$\begin{aligned}&\mathbb{E}_{\tau \sim \mathbb{P}_\theta} \left[\nabla_\theta \log \pi_\theta(a_t|s_t) \sum_{k=t}^{\infty} \gamma^{k-t} r(s_k, a_k) \right] \\ &= \mathbb{E} \left[\mathbb{E} \left[\nabla_\theta \log \pi_\theta(A_t|S_t) \sum_{k=t}^{\infty} \gamma^{k-t} r_k \middle| S_t, A_t \right] \right] \\ &= \mathbb{E} \left[\nabla_\theta \log \pi_\theta(A_t|S_t) \mathbb{E} \left[\sum_{k=t}^{\infty} \gamma^{k-t} r_k \middle| S_t, A_t \right] \right],\end{aligned}$$

第二个等号是因为 $\nabla_\theta \log \pi_\theta(A_t|S_t)$ 是 $\sigma(S_t, A_t)$ -可测的. 记**动作价值函数**为

$$Q^{\pi_\theta} = \mathbb{E} \left[\sum_{k=t}^{\infty} \gamma^{k-t} r_k \middle| S_t, A_t \right],$$

其表示在状态 S_t 下执行动作 A_t 后, 未来累计奖励的条件期望, 是 (S_t, A_t) 的函数. 于是策略梯度表达式变为

$$\nabla_\theta J(\theta) = \sum_{t=0}^{\infty} \gamma^t \mathbb{E}_{\tau \sim \mathbb{P}_\theta} [\nabla_\theta \log \pi_\theta(a_t|s_t) Q^{\pi_\theta}(s_t, a_t)].$$

为了降低策略梯度的方差, 我们可以引入一个**基线函数** $b: S \rightarrow \mathbb{R}$, 与 (5) 类似, 我们有

$$\mathbb{E} \left[\nabla_{\theta} \log \pi_{\theta}(A_t | S_t) b(S_t) \middle| S_t \right] = b(S_t) \mathbb{E} [\nabla_{\theta} \log \pi_{\theta}(A_t | S_t) | S_t] = 0.$$

为了最小化估计方差, 最好的选择是 $Q^{\pi_{\theta}}$ 的条件期望. 定义**状态价值函数**为

$$V^{\pi_{\theta}} = \mathbb{E}[Q^{\pi_{\theta}} | S_t] = \mathbb{E} \left[\sum_{k=t}^{\infty} \gamma^{k-t} r_k \middle| S_t \right],$$

此时 $V^{\pi_{\theta}}$ 是 S_t 的函数, 表示在状态 S_t 下未来累计奖励的条件期望. 差值 $A^{\pi_{\theta}} = Q^{\pi_{\theta}} - V^{\pi_{\theta}}$ 被称为**优势函数**, 表示在状态 S_t 下执行动作 A_t 相对于平均水平的优势. 由于

$$\mathbb{E} [\nabla_{\theta} \log \pi_{\theta}(A_t | S_t) V^{\pi_{\theta}}(S_t)] = \mathbb{E} [\mathbb{E} [\nabla_{\theta} \log \pi_{\theta}(A_t | S_t) V^{\pi_{\theta}}(S_t) | S_t]] = 0,$$

所以我们可以把策略梯度表达式改写成

$$\nabla_{\theta} J(\theta) = \sum_{t=0}^{\infty} \gamma^t \mathbb{E}_{\tau \sim \mathbb{P}_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) A^{\pi_{\theta}}(s_t, a_t)]. \quad (7)$$

记 $\nu_{t,\theta}$ 表示 $\mathbb{P}_{\theta}$ 在 (S_t, A_t) 下的推前测度. $t=0$ 时, 有

$$\nu_{0,\theta}(E \times F) = \mathbb{P}_{\theta}((S_0, A_0) \in E \times F) = \int_E \rho_0(ds_0) \int_F \pi_{\theta}(da_0 | s_0).$$

$t=1$ 时, 有

$$\begin{aligned} \nu_{1,\theta}(E \times F) &= \int_{S \times A} \int_{E \times F} K_{\theta}(ds_1, da_1 | s_0, a_0) \rho_0(ds_0) \pi_{\theta}(da_0 | s_0) \\ &= \int_{S \times A} \int_{E \times F} \mathcal{P}(ds_1 | s_0, a_0) \pi_{\theta}(da_1 | s_1) \rho_0(ds_0) \pi_{\theta}(da_0 | s_0) \\ &= \int_{S \times A} \nu_{0,\theta}(ds_0 da_0) \int_{E \times F} \mathcal{P}(ds_1 | s_0, a_0) \pi_{\theta}(da_1 | s_1). \end{aligned}$$

以此类推, 对于一般的 t , 我们有

$$\begin{aligned} \nu_{t,\theta}(E \times F) &= \int_{S \times A} \nu_{t-1,\theta}(ds_{t-1} da_{t-1}) \int_{E \times F} \mathcal{P}(ds_t | s_{t-1}, a_{t-1}) \pi_{\theta}(da_t | s_t) \\ &= \int_{S \times A} \nu_{t-1,\theta}(ds_{t-1} da_{t-1}) \int_E \mathcal{P}(ds_t | s_{t-1}, a_{t-1}) \pi_{\theta}(F | s_t) \\ &= \int_E \pi_{\theta}(F | s_t) \int_{S \times A} \nu_{t-1,\theta}(ds_{t-1} da_{t-1}) \mathcal{P}(ds_t | s_{t-1}, a_{t-1}) \\ &= \int_E \pi_{\theta}(F | s_t) \mu_{t,\theta}(ds_t) = \int_{E \times F} \pi_{\theta}(da_t | s_t) \mu_{t,\theta}(ds_t). \end{aligned}$$

其中

$$\mu_{t,\theta}(E) = \int_E \int_{S \times A} v_{t-1,\theta}(ds_{t-1} da_{t-1}) \mathcal{P}(ds_t | s_{t-1}, a_{t-1}) = v_{t,\theta}(E \times A)$$

是 S 上的测度.

于是 (7) 中的积分可以推前到 $S \times A$ 上的测度 $v_{t,\theta}$, 得到

$$\begin{aligned} \mathbb{E} [\nabla_{\theta} \log \pi_{\theta}(A_t | S_t) A^{\pi_{\theta}}(S_t, A_t)] &= \int_{S \times A} \nabla_{\theta} \log \pi_{\theta}(a | s) A^{\pi_{\theta}}(s, a) v_{t,\theta}(ds da) \\ &= \int_S \mu_{t,\theta}(ds) \int_A \nabla_{\theta} \log \pi_{\theta}(a | s) A^{\pi_{\theta}}(s, a) \pi_{\theta}(da | s), \end{aligned}$$

交换积分和求和, 得到

$$\nabla_{\theta} J(\theta) = \int_S \left(\sum_{t=0}^{\infty} \gamma^t \mu_{t,\theta}(ds) \right) \int_A \nabla_{\theta} \log \pi_{\theta}(a | s) A^{\pi_{\theta}}(s, a) \pi_{\theta}(da | s).$$

定义归一化折现状态分布为

$$\rho_{\pi_{\theta}}(E) = (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \mu_{t,\theta}(E),$$

其是 S 上的一个概率测度, 表示在策略 π_{θ} 下系统访问状态集 E 的归一化折现频率. 至此, 我们得到了需要的**最终策略梯度表达式**:

$$\begin{aligned} \nabla_{\theta} J(\theta) &= \frac{1}{1 - \gamma} \int_S \rho_{\pi_{\theta}}(ds) \int_A \nabla_{\theta} \log \pi_{\theta}(a | s) A^{\pi_{\theta}}(s, a) \pi_{\theta}(da | s) \\ &= \frac{1}{1 - \gamma} \mathbb{E}_{s \sim \rho_{\pi_{\theta}}, a \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a | s) A^{\pi_{\theta}}(s, a)]. \end{aligned} \tag{8}$$